

DATATHON 2026 - ROUND 1

BÁO CÁO CHI TIẾT PHẦN MODEL FORECASTING

Giải thích cách triển khai mô hình, cách sử dụng insight từ EDA và logic dự báo doanh thu

Hạng mục	Nội dung
Nguồn tham chiếu	GitHub Datathon2026/VinUniDatathon; Đề thi Vòng 1 Datathon 2026
Notebook chính	part3_forecasting/Model_final.ipynb
File submission	part3_forecasting/submission_direct.csv
Trọng tâm báo cáo	Phần model forecasting và cách chuyển insight EDA thành feature

Tóm tắt ngắn: Mô hình được xây dựng theo hướng machine learning forecasting cho dữ liệu chuỗi thời gian, sử dụng LightGBM và một hệ feature phong phú. Điểm cốt lõi của pipeline là không chỉ dựa vào doanh thu quá khứ, mà kết hợp nhiều tín hiệu từ EDA: mùa vụ, traffic, tồn kho, khuyến mãi, hành vi đơn hàng, hoàn trả, đánh giá khách hàng và xu hướng gần đây.

Mục lục nội dung

- 1. Mục tiêu bài toán
- 2. Tổng quan pipeline model
- 3. Dữ liệu đầu vào
- 4. Cách insight từ EDA được chuyển thành feature
- 5. Feature engineering chi tiết

- 6. Lựa chọn LightGBM
- 7. Train/validation theo thời gian
- 8. Direct forecasting và recursive forecasting
- 9. Đánh giá mô hình
- 10. Tạo file submission
- 11. Giải thích mô hình bằng ngôn ngữ kinh doanh
- 12. Hạn chế, lưu ý và hướng cải thiện
- 13. Kết luận
- Phụ lục. One-page defense script

1. Mục tiêu bài toán

Phần model forecasting giải quyết bài toán dự báo doanh thu theo ngày cho giai đoạn test từ 01/01/2023 đến 01/07/2024. Theo đề thi, mỗi dòng trong tập test tương ứng với một ngày và file nộp cuối cùng cần có đúng định dạng Date, Revenue, COGS.

Trọng tâm kỹ thuật của notebook là dự báo Revenue. Đây là biến mục tiêu chính trong bài toán sales forecasting. Các chỉ số đánh giá gồm MAE, RMSE và R2, trong đó MAE đo sai số tuyệt đối trung bình, RMSE phạt nặng hơn các sai số lớn, còn R2 cho biết mô hình giải thích được bao nhiêu phần biến động của doanh thu.

Vì dữ liệu là chuỗi thời gian, mục tiêu không chỉ là tìm mô hình có điểm số tốt, mà còn cần bảo đảm mô hình dự báo đúng logic thời gian: dùng dữ liệu quá khứ để dự báo tương lai, tránh trộn thông tin tương lai vào quá trình huấn luyện.

2. Tổng quan pipeline model

Pipeline model được tổ chức theo logic từ dữ liệu thô đến file submission cuối cùng. Có thể tóm tắt thành 7 bước:

1. Đọc dữ liệu đầu vào từ thư mục dataset, bao gồm sales, sample_submission, web_traffic, inventory, orders, order_items, promotions, returns, reviews và các datamart đã chuẩn hóa.
2. Kiểm tra cấu trúc sales.csv vì đây là bảng trung tâm chứa Date, Revenue và COGS.

3. Tạo calendar features để mô hình hiểu yếu tố thời gian, tuần, tháng, quý và mùa vụ.
4. Tổng hợp traffic, inventory và các bảng transaction thành feature theo ngày hoặc pattern lịch sử.
5. Tạo lag, rolling, EWM và momentum features từ Revenue quá khứ.
6. Chia train/validation theo thời gian: train đến hết 2021, validation năm 2022.
7. Huấn luyện LightGBM, đánh giá bằng MAE/RMSE/R2 và xuất submission.

Cách tiếp cận này phù hợp với bài toán kinh doanh vì doanh thu thương mại điện tử không chỉ phụ thuộc vào lịch sử bán hàng, mà còn chịu tác động từ nhu cầu thị trường, hiệu quả traffic, tình trạng tồn kho, chiến dịch khuyến mãi, chất lượng sản phẩm và hành vi hoàn trả.

3. Dữ liệu đầu vào

Notebook đọc bảng trung tâm là sales.csv, trong đó mỗi dòng là một ngày lịch sử và có Revenue, COGS. Đây là nguồn dữ liệu mục tiêu để huấn luyện mô hình.

Ngoài sales.csv, notebook sử dụng thêm nhiều bảng phụ trợ để tạo biến giải thích. Các bảng này cung cấp các góc nhìn khác nhau về hoạt động kinh doanh:

Bảng dữ liệu	Nội dung chính	Vai trò trong model
sales.csv	Revenue và COGS theo ngày	Biến mục tiêu và lịch sử doanh thu
sample_submission.csv	Danh sách ngày cần dự báo	Khung thời gian test, chỉ dùng cột Date
web_traffic.csv	Sessions, page views, bounce rate, duration	Tín hiệu nhu cầu và mức quan tâm của khách hàng
inventory.csv	Tồn kho, nhập hàng, bán ra, fill rate	Tín hiệu nguồn cung và khả năng đáp ứng đơn hàng
orders.csv	Đơn hàng, thiết bị, nguồn đơn, payment method	Hành vi mua và kênh tạo đơn

order_items.csv	Sản phẩm, quantity, unit price, discount, promo	Giá trị giỏ hàng và mức khuyến mãi
promotions.csv	Loại khuyến mãi, mức giảm, thời gian chạy	Tác động của campaign đến doanh thu
returns.csv	Số lượng hoàn trả, lý do, refund	Tín hiệu thất thoát và chất lượng bán hàng
reviews.csv	Rating, review count	Tín hiệu trải nghiệm khách hàng
leakage/profit datamart	Các biến tổng hợp về thất thoát, lợi nhuận, margin	Tín hiệu tài chính nâng cao nếu được tạo từ dữ liệu gốc

Quy mô dữ liệu trong notebook khá lớn, ví dụ orders có hơn 646 nghìn dòng, order_items có hơn 714 nghìn dòng, reviews có hơn 113 nghìn dòng và returns có gần 40 nghìn dòng. Điều này giúp mô hình có đủ thông tin để học các pattern kinh doanh đa chiều thay vì chỉ học chuỗi doanh thu đơn lẻ.

4. Cách insight từ EDA được chuyển thành feature

Một điểm quan trọng của phần model là việc sử dụng EDA không dừng ở mức mô tả biểu đồ. Các phát hiện từ EDA được chuyển hóa thành feature cụ thể để mô hình học được quy luật. Bảng dưới đây tóm tắt mối liên hệ giữa EDA và model.

Insight từ EDA	Ý nghĩa kinh doanh	Feature đưa vào model
Mùa vụ doanh thu	Doanh thu thay đổi theo ngày trong tuần, tháng, quý, đầu/cuối tháng và chu kỳ năm	Calendar features: month, day_of_week, is_weekend, quarter, is_month_start, is_month_end, sin/cos features
Traffic website	Nhiều phiên truy cập và nhiều page views thường là tín hiệu nhu cầu;	Traffic features: sessions, unique_visitors, page_views, bounce_rate,

	bounce rate cao có thể làm giảm chuyển đổi	pageviews_per_session, traffic_engagement
Tồn kho và supply	Doanh thu có thể bị giới hạn nếu hàng tồn thấp, fill rate thấp hoặc có áp lực stockout	Inventory features: stock_on_hand, units_sold, fill_rate, sell_through_rate, supply_efficiency, stockout_pressure
Khuyến mãi	Discount và promotion có thể kéo doanh thu lên nhưng cũng thay đổi hành vi mua	Promotion features: promo_line_ratio, avg_discount_rate, promo_active_count, promo_discount_value_mean/max
Hành vi đơn hàng	Số đơn, số khách, thiết bị đặt hàng và nguồn đơn phản ánh cấu trúc nhu cầu	Order pattern features: order_count, customer_count, mobile_order_ratio, paid_search_ratio, direct_ratio
Hoàn trả và refund	Return cao làm giảm doanh thu thực nhận và phản ánh rủi ro chất lượng	Return features: return_count, return_quantity_sum, refund_amount_sum
Review khách hàng	Rating thấp hoặc review xấu có thể báo hiệu vấn đề trải nghiệm	Review features: review_count, avg_rating, low_rating_ratio, high_rating_ratio
Xu hướng doanh thu	Doanh thu có quán tính, chu kỳ tuần/tháng/năm và biến động ngắn hạn	Lag, rolling, EWM, momentum features

Nhờ mapping này, phần model có thể giải thích rõ ràng: EDA giúp xác định yếu tố nào có khả năng ảnh hưởng đến doanh thu; sau đó model biến các yếu tố đó thành dữ liệu đầu vào để dự báo.

5. Feature engineering chi tiết

5.1. Calendar features

Calendar features giúp mô hình hiểu tính thời gian của doanh thu. Các biến như year, month, day, day_of_week, is_weekend, quarter, week_of_year cho phép mô hình phân biệt ngày thường với cuối tuần, tháng cao điểm với tháng thấp điểm, hoặc giai đoạn đầu tháng với cuối tháng.

Notebook còn tạo các biến sin/cos cho month, day_of_week và day_of_year. Đây là cách biểu diễn chu kỳ tốt hơn so với dùng số nguyên đơn thuần. Ví dụ, tháng 12 và tháng 1 gần nhau trong chu kỳ năm, nhưng nếu chỉ dùng số 12 và 1 thì mô hình có thể hiểu nhầm là chúng cách xa nhau.

Ví dụ nhóm biến:

year, month, day, day_of_week, is_weekend, quarter
day_of_year, week_of_year, is_month_start, is_month_end
month_sin, month_cos, dow_sin, dow_cos, doy_sin, doy_cos

5.2. Traffic features

Traffic là tín hiệu demand-side. Trong thương mại điện tử, doanh thu thường liên quan đến số người truy cập, số phiên, số lượt xem trang và mức độ tương tác trên website. Nếu traffic tăng nhưng bounce rate cũng tăng, điều đó có thể cho thấy nhiều người vào trang nhưng không chuyển đổi tốt.

Ví dụ nhóm biến:

sessions, unique_visitors, page_views, bounce_rate
avg_session_duration_sec, pageviews_per_session
sessions_per_visitor, traffic_engagement, bounce_sessions

Nhóm biến này giúp mô hình không chỉ nhìn vào lịch sử doanh thu, mà còn nhận biết nhu cầu thị trường trước khi doanh thu phát sinh.

5.3. Inventory features

Inventory phản ánh supply-side. Trong bán lẻ, doanh thu thực tế không chỉ phụ thuộc vào khách muốn mua bao nhiêu, mà còn phụ thuộc vào doanh nghiệp có đủ hàng để bán hay không. Vì vậy, notebook tổng hợp inventory theo tháng và merge vào dữ liệu ngày.

Biến inventory gốc:

stock_on_hand, units_received, units_sold
days_of_supply, fill_rate, reorder_flag, sell_through_rate

Biến mở rộng:

$\text{supply_efficiency} = \text{fill_rate} * \text{sell_through_rate}$

$\text{inventory_turnover_proxy} = \text{units_sold} / (\text{stock_on_hand} + 1)$

$\text{received_to_stock_ratio} = \text{units_received} / (\text{stock_on_hand} + 1)$

$\text{stockout_pressure} = \text{stockout_days} * \text{stockout_flag}$ nếu đủ dữ liệu

Về mặt kinh doanh, nếu fill_rate thấp hoặc stockout_pressure cao, mô hình có thể học rằng doanh thu có thể bị chặn bởi thiếu hàng, kể cả khi nhu cầu thị trường tốt.

5.4. Business pattern features

Do tập test là tương lai, các giao dịch thật trong tương lai không tồn tại. Vì vậy, notebook không sử dụng transaction tương lai, mà tổng hợp pattern lịch sử theo month/day rồi áp dụng cho các ngày cần dự báo. Đây là cách biến dữ liệu giao dịch thành quy luật mùa vụ kinh doanh.

Nhóm business pattern features gồm 31 biến, phản ánh order behavior, discount, promotion, return và review.

Ví dụ nhóm biến:

order_count , customer_count , $\text{mobile_order_ratio}$, $\text{desktop_order_ratio}$

paid_search_ratio , direct_ratio , $\text{email_campaign_ratio}$

cod_ratio , credit_card_ratio

avg_quantity , total_quantity , avg_unit_price

$\text{avg_discount_amount}$, avg_discount_rate , promo_line_ratio

return_count , $\text{return_quantity_sum}$, refund_amount_sum

review_count , avg_rating , low_rating_ratio , high_rating_ratio

Đây là phần thể hiện rõ nhất việc model sử dụng EDA: các bảng đơn hàng, khuyến mãi, hoàn trả và review được EDA phân tích để hiểu yếu tố kinh doanh, sau đó được chuyển thành pattern features cho mô hình.

5.5. Datamart features

Notebook sử dụng thêm $\text{leakage_datamart.csv}$ và $\text{profit_datamart.csv}$ để tạo các biến liên quan đến thất thoát, lợi nhuận, COGS thực tế, discount, phí vận chuyển, margin, tỷ lệ đơn hoàn trả và tỷ lệ khuyến mãi. Các biến này giúp mô hình có thêm góc nhìn tài chính sâu hơn.

Ví dụ nhóm biến profit/leakage:

profit_gmv_sum, profit_realized_revenue_sum
profit_actual_cogs_sum, profit_actual_discount_sum
profit_shipping_fee_sum, profit_net_profit_sum
profit_margin_mean, profit_promo_ratio, profit_returned_ratio
leak_total_financial_loss_sum, leak_refund_amount_sum
leak_cancelled_ratio, leak_returned_ratio

Lưu ý quan trọng: nếu các datamart này là bảng do nhóm tự tạo từ dữ liệu gốc, report nên giải thích quy trình tạo để đảm bảo tính tái lập. Nếu không giải thích, người đọc có thể hiểu nhầm đây là dữ liệu ngoài.

5.6. Lag, rolling, EWM và momentum features

Đây là nhóm feature quan trọng nhất của forecasting. Lag features đưa doanh thu quá khứ vào model, ví dụ doanh thu hôm qua, tuần trước, tháng trước hoặc cùng kỳ năm trước.

Lag features:

revenue_lag_1, revenue_lag_2, revenue_lag_3
revenue_lag_7, revenue_lag_14, revenue_lag_21, revenue_lag_28
revenue_lag_30, revenue_lag_60, revenue_lag_90
revenue_lag_180, revenue_lag_365

Rolling features tính thống kê trên các cửa sổ 7, 14, 30, 56 và 90 ngày, gồm mean, standard deviation, median, min và max. Điểm đúng kỹ thuật là notebook dùng Revenue.shift(1) trước khi rolling, nghĩa là chỉ sử dụng dữ liệu quá khứ, tránh dùng Revenue của ngày hiện tại để dự báo chính nó.

Rolling và EWM:

revenue_roll_mean_7, revenue_roll_std_7, revenue_roll_median_7
revenue_roll_mean_30, revenue_roll_std_30, revenue_roll_max_30
revenue_ewm_7, revenue_ewm_30

Momentum features giúp mô hình hiểu doanh thu đang tăng, giảm hay biến động mạnh. Ví dụ revenue_momentum_7_30 so sánh trung bình 7 ngày với trung bình 30 ngày; nếu tỷ lệ này lớn hơn 1, doanh thu ngắn hạn đang cao hơn mức trung hạn.

Momentum và ratio:

```
revenue_diff_1_7, revenue_diff_7_30, revenue_diff_28_365  
revenue_ratio_1_7, revenue_ratio_7_30, revenue_ratio_1_365  
revenue_momentum_7_30, revenue_momentum_30_90  
revenue_volatility_ratio_7_30, revenue_volatility_ratio_30_90
```

6. Lựa chọn LightGBM

Nhóm sử dụng LightGBM vì đây là mô hình gradient boosting mạnh cho dữ liệu dạng bảng. Với bài toán này, LightGBM phù hợp vì dữ liệu có nhiều nhóm feature khác nhau và quan hệ giữa các biến với Revenue có thể phi tuyến.

Ví dụ, traffic tăng không phải lúc nào doanh thu cũng tăng cùng tỷ lệ; khuyến mãi cao có thể tăng số đơn nhưng làm thay đổi giá trị đơn hàng; tồn kho thấp có thể làm doanh thu không tăng dù nhu cầu tốt. LightGBM có khả năng học các quan hệ phức tạp như vậy thông qua hệ cây quyết định tăng cường.

- Ưu điểm 1: xử lý tốt dữ liệu bảng với nhiều feature.
- Ưu điểm 2: học được quan hệ phi tuyến và tương tác giữa biến.
- Ưu điểm 3: thường cho hiệu quả tốt với feature engineering thủ công.
- Ưu điểm 4: có thể giải thích bằng feature importance hoặc SHAP.

7. Train/validation theo thời gian

Trong forecasting, random split là không phù hợp vì có thể làm lẫn dữ liệu tương lai vào quá khứ. Notebook chia dữ liệu theo thời gian: dữ liệu đến hết năm 2021 dùng để train, dữ liệu năm 2022 dùng để validation.

Train: year <= 2021

Validation: year == 2022

Cách chia này mô phỏng đúng tình huống thực tế: tại thời điểm dự báo, doanh nghiệp chỉ có dữ liệu quá khứ và cần dự báo tương lai. Sau khi tạo lag và rolling, các dòng thiếu ở đầu chuỗi được loại bỏ. Tập model_df còn 3.468 dòng và 165 cột; tập train có 3.103 dòng, validation có 365 dòng.

8. Direct forecasting và recursive forecasting

README cho biết notebook có so sánh recursive forecasting và direct forecasting. Hai cách này khác nhau như sau:

Phương pháp	Cách hoạt động	Ưu/nhược điểm
Recursive forecasting	Dự báo ngày đầu tiên, sau đó dùng giá trị dự báo đó làm input cho ngày tiếp theo	Tận dụng được cấu trúc lag nhưng dễ lan truyền sai số nếu dự báo ban đầu lệch
Direct forecasting	Dự báo từng ngày test độc lập hơn, dùng các feature không phụ thuộc trực tiếp vào Revenue dự báo trước đó	Giảm rủi ro lan truyền sai số, phù hợp khi test kéo dài nhiều ngày

Notebook tạo `direct_feature_cols` gồm 97 features, loại bỏ các biến phụ thuộc vào Revenue dự báo trước đó như lag, rolling, EWM và momentum. Điều này cho thấy nhóm ưu tiên hướng dự báo ổn định hơn cho toàn bộ giai đoạn test.

9. Đánh giá mô hình

Theo đề thi, mô hình được đánh giá bằng MAE, RMSE và R2. Notebook dùng early stopping trong quá trình huấn luyện LightGBM để tránh overfitting. Log huấn luyện cho thấy best iteration ở vòng 398, với validation RMSE khoảng 699.644.

RMSE là chỉ số nhạy với sai số lớn, nên việc tối ưu RMSE giúp mô hình hạn chế những ngày dự báo lệch mạnh. Early stopping giúp mô hình dừng khi hiệu quả trên validation không còn cải thiện, từ đó giảm nguy cơ học quá sát dữ liệu train.

Để phần giải thích model mạnh hơn, nên bổ sung feature importance hoặc SHAP plot. Điều này giúp trả lời câu hỏi: các yếu tố nào đang dẫn động doanh thu trong mô hình? Ví dụ, nếu top features gồm `revenue_lag_7`, `traffic_engagement`, `promo_line_ratio` và `fill_rate`, nhóm có thể giải thích rằng doanh thu phụ thuộc mạnh vào chu kỳ tuần, chất lượng traffic, mức khuyến mãi và khả năng cung ứng.

10. Tạo file submission

Sau khi huấn luyện, notebook tạo file submission chính tại `part3_forecasting/submission_direct.csv`. File này cần giữ đúng thứ tự Date theo `sample_submission.csv` và gồm đúng ba cột Date, Revenue, COGS.

File output:

`part3_forecasting/submission_direct.csv`

Format:

Date, Revenue, COGS

README cũng nhấn mạnh rằng notebook cần được chạy trong đúng thư mục `part3_forecasting` vì đường dẫn dữ liệu được thiết lập theo `BASE_DIR = Path.cwd()` và `DATA_DIR = BASE_DIR / "dataset"`. Đây là một điểm quan trọng để đảm bảo người khác có thể chạy lại kết quả.

11. Giải thích mô hình bằng ngôn ngữ kinh doanh

Có thể giải thích mô hình theo cách dễ hiểu như sau: mô hình không chỉ nhìn vào doanh thu quá khứ, mà kết hợp cả tín hiệu về nhu cầu và tín hiệu về khả năng cung ứng.

Demand-side signals gồm traffic website, số đơn hàng lịch sử, số khách, nguồn đơn, thiết bị đặt hàng, khuyến mãi và review. Những biến này giúp mô hình hiểu khi nào nhu cầu thị trường mạnh hơn hoặc yếu hơn.

Supply-side signals gồm stock_on_hand, units_received, fill_rate, sell_through_rate và stockout_pressure. Những biến này giúp mô hình hiểu doanh thu có thể bị giới hạn bởi nguồn cung, kể cả khi nhu cầu tăng.

Historical signals gồm lag, rolling, EWM và momentum features. Những biến này giúp mô hình hiểu doanh thu có quán tính, chu kỳ và xu hướng gần đây.

Tín hiệu	Diễn giải kinh doanh	Tác động kỳ vọng
Traffic tăng, bounce rate thấp	Nhu cầu và chất lượng truy cập tốt hơn	Revenue có thể tăng
Fill rate thấp hoặc stockout pressure cao	Doanh nghiệp có thể không đủ hàng để bán	Revenue có thể bị giới hạn

Promo_line_ratio và discount tăng	Khuyến mãi kích thích mua hàng	Revenue có thể tăng nhưng biên lợi nhuận cần theo dõi
Return_count hoặc low_rating_ratio cao	Trải nghiệm khách hàng hoặc chất lượng sản phẩm có vấn đề	Revenue thực nhận và tăng trưởng tương lai có thể bị ảnh hưởng
Rolling mean 7 ngày cao hơn 30 ngày	Xu hướng ngắn hạn đang tăng	Model có thể dự báo mức Revenue cao hơn

12. Hạn chế, lưu ý và hướng cải thiện

12.1. Lưu ý về datamart

Hai file leakage_datamart.csv và profit_datamart.csv cần được mô tả rõ trong report. Nếu đây là file nhóm tự tạo từ các bảng gốc, cần ghi rõ cách tạo và nên để kèm script tạo file để đảm bảo tính tái lập. Nếu không giải thích, người đọc có thể hiểu nhầm là dữ liệu ngoài.

12.2. Kiểm soát leakage

Trong forecasting, leakage xảy ra khi mô hình vô tình sử dụng thông tin của tương lai để dự báo quá khứ hoặc hiện tại. Notebook đã xử lý tốt ở nhóm lag/rolling bằng cách dùng shift(1). Tuy nhiên, với các pattern tổng hợp theo month/day, cần giải thích rõ rằng đó là pattern lịch sử được tạo từ dữ liệu có sẵn trước thời điểm test.

12.3. Explainability

Đề bài yêu cầu có giải thích các yếu tố dẫn động doanh thu chính. Vì vậy, phần report nên có ít nhất một bảng feature importance hoặc SHAP summary. Nội dung này sẽ giúp biến model từ một "black box" thành một công cụ có thể giải thích bằng ngôn ngữ kinh doanh.

12.4. Hướng cải thiện

- Thêm TimeSeriesSplit hoặc rolling validation để đánh giá ổn định qua nhiều giai đoạn.

- Tạo baseline đơn giản như seasonal naive hoặc moving average để chứng minh LightGBM tốt hơn baseline.
- Bổ sung feature importance/SHAP để giải thích top drivers của Revenue.
- Kiểm tra riêng các ngày spike/outlier để xem model dự báo tốt hay chưa.
- Tách pipeline thành script train.py và predict.py để tăng khả năng tái lập.

13. Kết luận

Mô hình forecasting được xây dựng theo hướng machine learning cho chuỗi thời gian, sử dụng LightGBM và hệ feature phong phú. Điểm mạnh của cách triển khai là kết hợp được nhiều lớp dữ liệu: thời gian, traffic, inventory, orders, promotions, returns, reviews, datamart tài chính và lịch sử Revenue.

Các insight từ EDA được chuyển hóa thành feature rõ ràng. Mùa vụ trở thành calendar features; traffic trở thành demand features; tồn kho trở thành supply-side features; promotion, return và review trở thành business pattern features; xu hướng doanh thu trở thành lag, rolling, EWM và momentum features.

Cách chia validation theo thời gian giúp đánh giá mô hình sát với bối cảnh thực tế. Việc dùng LightGBM phù hợp với dữ liệu dạng bảng nhiều feature và có khả năng học quan hệ phi tuyến giữa các yếu tố kinh doanh với Revenue. Nhìn chung, pipeline thể hiện tư duy đầy đủ từ EDA -> feature engineering -> modeling -> validation -> submission.

Phụ lục. One-page defense script

Đoạn dưới đây có thể dùng để trình bày miệng ngắn gọn về phần model:

Trong phần forecasting, nhóm em xây dựng mô hình LightGBM để dự báo doanh thu theo ngày. Thay vì chỉ dùng doanh thu quá khứ, nhóm chuyển các insight từ EDA thành nhiều nhóm feature có ý nghĩa kinh doanh. Cụ thể, yếu tố mùa vụ được mã hóa thành calendar features; traffic website được dùng như tín hiệu nhu cầu; inventory được dùng để phản ánh khả năng cung ứng; còn orders, promotions, returns và reviews được tổng hợp thành business pattern features theo lịch sử month/day.

Với chuỗi doanh thu, nhóm tạo thêm lag, rolling, EWM và momentum features để mô hình học được chu kỳ tuần, tháng, năm và xu hướng tăng giảm gần đây. Các rolling

features đều dùng shift(1), nghĩa là chỉ lấy thông tin quá khứ, giúp tránh leakage. Dữ liệu được chia theo thời gian, train đến hết năm 2021 và validation trên năm 2022, mô phỏng đúng tình huống dùng quá khứ để dự báo tương lai.

Mô hình LightGBM được chọn vì phù hợp với dữ liệu bảng nhiều feature và có khả năng học quan hệ phi tuyến giữa doanh thu với traffic, promotion, tồn kho và hành vi khách hàng. Kết quả validation cho thấy mô hình đạt RMSE khoảng 699.644 tại best iteration 398. Cuối cùng, notebook tạo file submission_direct.csv đúng định dạng Date, Revenue, COGS để nộp lên Kaggle.